

MARIUS BARTH

# FORSCHUNGSMETHODEN IM BIOLOGIEUNTERRICHT



# *Inhalt*

*Vorwort*      5

*1 Messen*      7

1.1 *Skalen und Skalenniveaus*      9

1.2 *Messbarkeit und Messfehler*      10

*Aufgaben*      11

*2 Beschreiben und Zusammenfassen*      13

2.1 *Häufigkeitsverteilungen*      13

2.2 *Statistische Kennwerte*      14

*Aufgaben*      16

*Lösungen*      19

*Kapitel 1: Messen*      19

*Kapitel 2: Beschreiben und Zusammenfassen*      20



## *Vorwort*



# 1

## Messen

Bei einer Datenerhebung geht es darum, bestimmte *Merkmale* – Eigenschaften der untersuchten Merkmalsträger (Personen, Gruppen, Objekte, ...) – zu erfassen. Die individuellen *Ausprägungen* der Merkmale (die Werte der Variablen) werden dann zu einem Datensatz zusammengeführt und gespeichert. Weil diese Merkmale zwischen den Merkmalsträgern variieren können, spricht man auch von *Variablen*. (Unveränderliche Größen nennt man *Konstanten*.) Damit man die Merkmalsausprägungen in einem Datensatz speichern und weiter verarbeiten kann, muss man sie zunächst in symbolische Zeichen (z.B. Zahlen) “übersetzen”. Diesen Vorgang nennen wir *Messen*.

Aus dem Alltag ist uns das Messen von vielen Merkmalen vollkommen vertraut: Wenn wir die Körpergröße einer Person wissen wollen, nehmen wir z.B. ein Maßband zur Hand, messen sie kurz und schreiben uns die Körpergröße in Zentimetern oder Metern auf. Wenn wir unser Körpergewicht kennen wollen, wiegen wir uns auf einer Personenwaage und notieren das Gewicht in Kilogramm. Bei diesen Merkmalen ist uns also schon eine Übersetzung von Merkmalsausprägungen in Zahlen geläufig.

Bei anderen Merkmalen ist es aber gar nicht so einfach, einer bestimmten Ausprägung auch einen ganz bestimmten Zahlenwert zuzuordnen. Würden wir z.B. eine Schulklasse nach ihren Lieblingsgerichten fragen, bekämen wir Antworten wie “Pizza”, “Mangoldquiche” oder “Reis mit Ketchup”, aber keine Zahlen, die wir uns ohne weiteres notieren können. Um aber dennoch auch solche Merkmale messen zu können, benötigen wir also eine Übersetzung von diesen Begriffen in Zahlen. Es gibt eine Reihe von Regeln, die einem dabei helfen eine möglichst sinnvolle Übersetzung anzufertigen. Das Ziel dieser Regeln ist es, dass sich die *Beziehungen*, die zwischen den Ausprägungen des Merkmals herrschen, auch in den Beziehungen zwischen den Zahlen wiederfinden (man spricht von den *erhaltenen Relationen*).

1. Gleichheit und Verschiedenheit: Wenn sich die Ausprägungen eines Merkmals unterscheiden, sollen sich auch die Zahlen, in die man sie übersetzt, unterscheiden (z.B. bekommen alle Schüler, die "Pizza" gesagt haben, eine 1, all jene, die "Mangoldquiche" gesagt haben, aber eine 2). Wenn die Ausprägungen aber gleich sind, dann sollen auch die zugeordneten Zahlen gleich sein (z.B. bekommen wirklich alle Schüler, die "Pizza" gesagt haben, auch eine 1).
2. Ordnung: Manchmal lassen sich die Ausprägungen eines Merkmals in eine sinnvolle Reihenfolge bringen, indem man die Ausprägungen nach ihrer Größe, Stärke oder Intensität ordnet. Würde man z.B. einen einzelnen Schüler zu mehreren Gerichten befragen, wie gerne er diese mag, und ihn seine Antworten "auf einer Skala von 1 bis 10" geben lassen (mit einer 10 als bestem Wert), könnte man sich ziemlich sicher sein, dass eine 10 eine größere Vorliebe widerspiegelt als eine 9. Ob aber der Unterschied zwischen einer 9 und einer 10 *genauso groß* ist wie der Unterschied zwischen einer 8 und einer 9, könnte man nicht sicher sagen. Ein anderes Beispiel für ordinalskalierte Variablen sind Rangfolgen, also z.B. die Gold-, Silber- und Bronzemedailles bei den olympischen Spielen. Wir wüssten, dass eine Goldmedaille eine bessere Leistung als eine Silbermedaille anzeigen soll; vielleicht war aber der Leistungsunterschied zwischen Gold und Silber viel kleiner (oder viel größer) als der zwischen Silber und Bronze.
3. Größe der Verschiedenheit: Zusätzlich zu der Ordnung der Merkmalsausprägungen ist es manchmal möglich, auch Aussagen darüber zu treffen, *wie groß* die Unterschiede zwischen zwei Merkmalsausprägungen ist. Dies ist z.B. Bei der Temperatur in Grad Celsius möglich: Der Temperaturunterschied zwischen  $10^{\circ}\text{C}$  und  $20^{\circ}\text{C}$  ist genauso groß wie der Temperaturunterschied zwischen  $20^{\circ}\text{C}$  und  $30^{\circ}\text{C}$ . Man kann allerdings nicht sagen, dass  $30^{\circ}\text{C}$  warmes Wasser dreimal so warm ist wie  $10^{\circ}\text{C}$  warmes Wasser.
4. Verhältnis der Merkmalsausprägung: Zusätzlich kann es möglich sein, auch Aussagen über das Verhältnis mehrerer Merkmalsausprägungen zueinander treffen. Dies ist bei vielen physikalischen Größen wie z.B. der Masse eines Körpers möglich: 100 kg sind 100-mal so viel wie 1 kg. Solche Variablen haben einen natürlichen Nullpunkt, z.B. besagt eine Masse von 0 kg, dass tatsächlich *keine* Masse vorhanden ist.
5. Absolute Werte: Schließlich kann es noch möglich sein, dass das Merkmal in einer natürlichen Einheit vorliegt, d.h. auch die Abstände zwischen zwei Merkmalsausprägungen sind natürlich gegeben. Dies ist der Fall für absolute Häufigkeiten, also z.B. die Häufigkeit, wie oft sich jemand in einer Unterrichtsstunde gemel-



det hat.

### 1.1 Skalen und Skalenniveaus

Die Zuordnung von bestimmten Zahlen zu Ausprägungen eines Merkmals nennen wir *Skala*. Je nachdem, welche der Regeln beim Übersetzen in Zahlen berücksichtigt wurden, unterscheidet man unterschiedliche *Skalenniveaus*.

1. Eine Skala, die nur die Regel von Gleichheit/Verschiedenheit befolgt, nennen wir *Nominalskala*.
2. Eine Skala, die zusätzlich zu Gleichheit/Verschiedenheit auch die Rangreihenfolge der Merkmalsausprägungen in Zahlen abbildet, nennen wir *Ordinalskala*.
3. Eine Skala, die zusätzlich auch die Größe der Verschiedenheit abbildet, nennen wir *Intervallskala*.
4. Eine Skala, die zusätzlich auch das Verhältnis der Merkmalsausprägungen abbildet, nennen wir *Verhältnisskala*.
5. Eine Skala, die zusätzlich auch eine natürliche Maßeinheit abbildet, nennen wir *Absolutskala*. Mit diesem Skalenniveau haben wir regelmäßig dann zu tun, wenn wir betrachten, wie *häufig* ein Merkmal aufgetreten ist bzw. wie *viele* Beobachtungen einer bestimmten Art wir machen. Ein Beispiel wäre die Anzahl der Versuche, die jemand braucht, um ein Rad zu schlagen.

Tabelle 1.1 gibt eine Übersicht über die erhaltenen Beziehungen (= Relationen) für die fünf vorgestellten Skalenniveaus. Das Skalenniveau entscheidet häufig darüber, welche Aussagen über eine Variable sinnvoll zu treffen sind und (später) wie wir sie beschreiben, zusammenfassen und (später) auswerten können. Je *höher* das Skalenniveau ist, d.h. je mehr der Relationen erhalten sind, desto mehr Aussagen sind sinnvoll zu treffen. Deshalb ist es wünschenswert, ein Merkmal möglichst immer auf einem möglichst hohen Skalenniveau zu messen.

Tabelle 1.1: Übersicht über die vorgestellten *Skalenniveaus* und die jeweils erhaltenen *Relationen*.

Skala	Gleichheit/ Verschiedenheit	Ordnung	Größe der Verschiedenheit	Verhältnisse	absolute Werte
Nominal-	ja	nein	nein	nein	nein
Ordinal-	ja	ja	nein	nein	nein
Intervall-	ja	ja	ja	nein	nein
Verhältnis-	ja	ja	ja	ja	nein
Absolut-	ja	ja	ja	ja	ja

## 1.2 Messbarkeit und Messfehler

Jede Messung ist mit einem mehr oder weniger großen *Messfehler* behaftet. Damit ist gemeint, dass der Messwert niemals exakt der Ausprägung des Merkmals entspricht. Hierfür gibt es mindestens zwei Gründe:

Der erste Grund liegt darin, dass jedes reale Messinstrument hat nur eine begrenzte Genauigkeit besitzt. Wenn wir z.B. ein Lineal mit einer Millimetereinteilung verwenden, können wir nicht auf den Zehntel- oder Hundertstelmillimeter genau ablesen. Auch wenn wir uns mehrmals nacheinander mit einer Personenwaage wiegen, wird sie nicht immer exakt den gleichen Wert anzeigen, obwohl es unwahrscheinlich ist, dass sich unser Gewicht innerhalb eines Augenblicks geändert hat – die Abweichungen entstehen durch Ungenauigkeiten des Messinstruments.

Der zweite Grund liegt darin, dass viele Merkmale, für die wir uns interessieren, gar nicht *direkt messbar* sind. Beispielsweise soll es ja vielleicht in einer Klassenarbeit darum gehen, die Fähigkeit oder das Wissen der Schüler in einem bestimmten Bereich zu messen. Die Note der Klassenarbeit (die in diesem Fall unser Messinstrument für die Fähigkeit sein soll), wird aber auch durch viele andere Dinge beeinflusst, z.B. ob man am Tag der Klassenarbeit einen guten Tag hatte, ob man mit der Art, wie der Lehrer die Aufgaben stellt, zurechtkommt, man während der Arbeit auf Toilette musste und deshalb Zeit verloren hat, und viele andere mögliche Störeinflüsse.

### *Aufgaben*

Überlegt in 2er- oder 3er-Gruppen, welches Skalenniveau die folgenden Variablen aufweisen. Hierzu ist es sinnvoll, zunächst zu überlegen, welches Merkmal die Variable wohl eigentlich erfassen soll und welche Relationen (= Beziehungen zwischen den Merkmalsausprägungen) erhalten sind.

- a) Das bei uns geläufige metrische System zur Messung von Distanzen in Millimetern, Zentimetern, Metern, oder Kilometern;
- b) die Nummern der Straßenbahnen der KVB (Kölner Verkehrsbetriebe);
- c) Schulnoten;
- d) Postleitzahlen.



## 2

# Beschreiben und Zusammenfassen

Die *deskriptive Statistik* beschäftigt sich mit der Frage, wie Merkmale bzw. Variablen sinnvoll beschrieben und zusammengefasst werden können. Wichtige Methoden hierzu sind *Häufigkeitsverteilungen* und *statistische Kennwerte*, die wir in diesem Kapitel vorstellen werden.

### 2.1 Häufigkeitsverteilungen

Um ein Merkmal zu beschreiben, kann man sich dessen *Häufigkeitsverteilung* anschauen. Die Häufigkeitsverteilung eines Merkmals ist charakterisiert durch (1) die Gesamtheit der unterschiedlichen Merkmalsausprägungen und (2) die Häufigkeit, mit der diese Ausprägungen vorkommen. Sie lässt sich in Form von Häufigkeitstabellen oder in einem Diagramm wie Abbildung 2.1 darstellen.

In diesem ersten Beispiel gibt es nur vier unterschiedliche Merkmalsausprägungen (Lieblingsgerichte), deshalb lässt sich die Häufigkeitsverteilung noch leicht in einem Diagramm darstellen. Wenn es aber sehr viele unterschiedliche Merkmalsausprägungen gibt, könnte man aber auch *Kategorien von Merkmalsausprägungen* bilden, um diese dann als sog. *sekundäre Häufigkeitsverteilung* darzustellen. Z.B. wäre es denkbar, dass die Schüler viele unterschiedliche Nudelgerichte angegeben hätten, die man dann zu der Kategorie "Nudelgerichte" zusammengefasst hätte.

Betrachtet man die Häufigkeitsverteilung eines Merkmals wie der Körpergröße von Schülern in einer Klasse, merkt man schnell, dass man nicht für jede Merkmalsausprägung eine eigene Säule zeichnen möchte: Hat man die Körpergröße z.B. auf den Zentimeter genau gemessen, wird es in einer Klasse kaum zwei Schüler geben, die genau gleich groß sind und jede Säule hätte die Höhe 1. Deshalb ist es bei intervall- und verhältnisskalierten Variablen oft sinnvoll, gleich eine sekundäre Häufigkeitsverteilung zu zeichnen. Die häufigste Form der Darstellung ist bei solchen Variablen eine besondere Form des Säulendiagramms, das *Histogramm*: Bei ihm ist auch die Breite




Abbildung 2.1: Die Häufigkeitsverteilung der nominalskalierten Variable \*Lieblingsgericht\*. Die x-Achse bezeichnet die Ausprägung des Merkmals, die Höhe der Verteilung (y-Wert) gibt Aufschluss über die Häufigkeit der zugehörigen Merkmalsausprägung.

der Säulen und somit die Fläche der Säulen interpretierbar; man sieht so anhand der Flächen relativ schnell, wie sich das Merkmal auf dessen Ausprägungsbereiche verteilt.

## 2.2 Statistische Kennwerte

Um die Häufigkeitsverteilung eines Merkmals zusammenfassend zu beschreiben, verwendet man zusätzlich *statistische Kennwerte*, die bestimmte Eigenschaften der Häufigkeitsverteilung in Zahlen zusammenfassen sollen. Hierzu unterscheidet man (1) *Lagemaße* bzw. *Maße der zentralen Tendenz* und (2) *Streuungs-* bzw. *Dispersionsmaße*. Lagemaße beantworten die Frage „Wo auf der Skala liegen die Messwerte?“, Streuungsmaße beantworten die Frage „Wie stark unterscheiden sich die Messwerte voneinander?“.

Sowohl für die Lage als auch die Streuung gibt es viele unterschiedliche Kennwerte – welchen Kennwert man am besten verwendet, hängt nämlich davon ab, welches Skalenniveau die Variable, die wir beschreiben möchten, aufweist.

### 2.2.1 Lagemaße

*Modus* bzw. *Moduswert*. Der Modus  $M_o$  ist derjenige Wert einer Variablen, der *am häufigsten* vorkommt. Man „berechnet“ ihn also, indem man zählt, wie häufig jede einzelne Merkmalsausprägung vorkommt und die häufigste Ausprägung aufschreibt. Der Modus ist schon ab Nominalskalenniveau interpretierbar. In unseren Beispiel aus Kapitel 1, in dem wir eine Schulklasse nach ihren Lieblingsgerichten gefragt haben, wäre also der Modus der Variable Lieblingsgericht der Wert „Pizza“ – genau jene Antwort, die am häufigsten genannt wurde. Hätten wir den einzelnen Gerichten Zahlen zugeordnet, z.B. „Pizza“ = 1, „Pommes“ = 2, usw., wäre der Modus  $M_o = 1$ . Das ist genau der Zahlenwert, den wir zuvor der Antwort „Pizza“ zugeordnet hatten.

*Median*. Der Median  $M_d$  ist derjenige Wert einer Variablen, der alle Werte, die man vorher der Größe nach geordnet hat, genau in der Mitte halbiert. Um ihn zu berechnen, ordnet man also zunächst alle Werte der Größe nach und schaut dann, welcher Wert genau in der Mitte dieser geordneten Zahlenreihe steht. Der Median ist dann sinnvoll interpretierbar, wenn die Variable mindestens Ordinalskalenniveau aufweist, sich die Werte also sinnvoll der Größe, Intensität oder Stärke nach ordnen lassen. Ein gutes Beispiel hierfür sind Schulnoten.

*Mittelwert*. Der Mittelwert  $M$  ist der Durchschnitt der Werte einer Variablen. Ihn kann man am leichtesten bestimmen, indem man (1) alle beobachteten Werte aufsummiert und dann (2) durch die Anzahl der beobachteten Werte teilt. Damit der Mittelwert sinnvoll inter-




Abbildung 2.2: Histogramm der gemessenen Körpergröße in einer 10. Klasse.




Abbildung 2.3: Zwei Häufigkeitsverteilungen mit unterschiedlicher Lage, aber gleicher Streuung.



Abbildung 2.4: Zwei Häufigkeitsverteilungen mit gleicher Lage, aber unterschiedlicher Streuung.

pretierbar ist, muss die Variable mindestens Intervallskalenniveau aufweisen. Ein gutes Beispiel hierfür ist die Temperatur in Grad Celsius: Haben wir einen Eimer mit  $10^{\circ}\text{C}$  warmen Wasser und einem Eimer mit  $20^{\circ}\text{C}$  warmen Wasser, können wir sagen, dass die Temperatur des Wassers in den beiden Eimern im Durchschnitt oder im Mittel  $15^{\circ}\text{C}$  beträgt. Das geht deshalb, da der Unterschied von  $15^{\circ}\text{C}$  zu  $10^{\circ}\text{C}$  genauso groß ist wie der Unterschied von  $15^{\circ}\text{C}$  zu  $20^{\circ}\text{C}$  (nämlich jeweils  $5^{\circ}\text{C}$ ).

### 2.2.2 Streuungsmaße

*Range bzw. Variationsbreite.* Der Range  $v$  (engl. für Reichweite/Bandbreite) bezeichnet den Umfang der Werte einer Variable. Im Falle einer nominalskalierten Variable berechnet er sich als die Anzahl unterschiedlicher Merkmalsausprägungen, die beobachtet wurden (wenn z.B. nur drei unterschiedliche Lieblingsgerichte genannt, ist der Range  $v = 3$ ). Im Falle von mindestens ordinalskalierten Variablen bezeichnet er die Differenz zwischen dem höchsten und niedrigsten beobachteten Wert der Variablen. (Besser ist es im Falle von nominal- oder ordinalskalierten Variablen, den sog. *relativen Informationsgehalt*  $H$  zu berechnen.)

*Interquartilsbereich.* Der Interquartilsbereich IQB bezeichnet den Bereich der Werte einer Variable, der die Hälfte aller Beobachtungen umfasst, die, wenn man die Werte der Reihe nach ordnet, in der Mitte liegen. Man kann also auch sagen, dass man die Werte der Variable der Reihe nach ordnet, das unterste Viertel (mit den kleinsten Werten) und das oberste Viertel (mit den größten Werten) abschneidet, und dann schaut, welche Werte die Variable an diesen Schnittpunkten hat. Da man die Werte hierfür in eine Ordnung bringen muss, kann man den Interquartilsbereich erst ab Ordinalskalenniveau berechnen.

*Standardabweichung.* Die Standardabweichung  $SD$  ist das wohl wichtigste und am häufigsten verwendete Maß der Dispersion. Leider lässt es sich nicht ganz so leicht berechnen, denn man muss (1) für jeden Wert der Variablen den Abstand zum Mittelwert der Variablen berechnen, (2) diese Abstände dann jeweils quadrieren, (3) die quadrierten Abstände aufsummieren, (4) diese Summe durch die Anzahl der Beobachtungen teilen und (5) aus dieser Summe die Wurzel ziehen. Das klingt ziemlich kompliziert, muss man aber zum Glück praktisch nie von Hand machen. Um zu verstehen, was die Standardabweichung ausdrückt, kann man sich vorstellen, dass sie ungefähr dem Wert entspricht, den die Messwerte (betragsmäßig) durchschnittlich vom Mittelwert abweichen (wobei große Abweichungen aber etwas stärker gewichtet werden). Es lässt sich erst ab

Intervallskalenniveau berechnen, da erst hier die Größen von Abständen bzw. Unterschieden sinnvoll interpretierbar sind.

Tabelle 1.2 zeigt einen Überblick, ab welchem Skalenniveau man welchen der vorgestellten Kennwerte berechnen darf.

Tabelle 2.1: Übersicht über die vorgestellten Lage- und Streuungsmaße und auf welchem Skalenniveau man sie sinnvoll berechnen kann.

Skala	Modus	Median	Mittelwert	Range	<i>IQB</i>	<i>SD</i>
Nominal-	ja	nein	nein	ja	nein	nein
Ordinal-	ja	ja	nein	ja	ja	nein
Intervall-	ja	ja	ja	ja	ja	ja
Verhältnis-	ja	ja	ja	ja	ja	ja
Absolut-	ja	ja	ja	ja	ja	ja

## Aufgaben

1. Zeichnet ein Histogramm der Variable *Alter* in der folgenden Tabelle.

Tabelle 2.2: Die Häufigkeitsverteilung der Variablen *Geschlecht* und *Alter* in einer Erstsemesterveranstaltung der Uni Köln.

Nr.	Geschlecht	Alter	Nr.	Geschlecht	Alter
1	weiblich	33	21	männlich	19
2	weiblich	28	22	weiblich	21
3	männlich	21	23	männlich	27
4	weiblich	26	24	weiblich	44
5	weiblich	25	25	weiblich	24
6	weiblich	22	26	weiblich	29
7	weiblich	22	27	weiblich	27
8	männlich	37	28	weiblich	19
9	weiblich	27	29	weiblich	21
10	weiblich	25	30	weiblich	25
11	weiblich	21	31	weiblich	25
12	weiblich	19	32	weiblich	24
13	weiblich	26	33	weiblich	21
14	weiblich	19	34	männlich	28
15	weiblich	19	35	weiblich	37
16	weiblich	22	36	weiblich	23
17	weiblich	31	37	weiblich	20
18	weiblich	24	38	weiblich	21



Nr.	Geschlecht	Alter	Nr.	Geschlecht	Alter
19	weiblich	27	39	weiblich	19
20	weiblich	24	40	weiblich	22

2. Zeichnet ein Histogramm der Variable *Alter* aus der vorigen Aufgabe. Zeichnet dieses Mal jedoch eine sekundäre Häufigkeitsverteilung, beginnend mit der Kategorie "18-21 Jahre".
3. Berechnet den Modus der Variable *Geschlecht* aus Aufgabe 1.
4. Berechnet den Mittelwert der Variable *Alter* aus Aufgabe 1.
5. Erläutert, warum es nicht sinnvoll ist, den Median der Variable *Geschlecht* zu berechnen.



# Lösungen

## Kapitel 1: Messen

Überlegt in 2er- oder 3er-Gruppen, welches Skalenniveau die folgenden Variablen aufweisen:

- a) Das bei uns geläufige metrische System zur Messung von Distanzen in Millimetern, Zentimetern, Metern, oder Kilometern;
- b) die Nummern der Straßenbahnen der KVB (Kölner Verkehrsbetriebe);
- c) Schulnoten;
- d) Postleitzahlen.

Das metrische System weist Verhältnisskalenniveau auf: Die Relation *Gleichheit/Verschiedenheit* ist erhalten, denn 1 m ist etwas anderes als 2 m, aber 1 m ist immer das gleiche. Die Relation *Ordnung* ist erhalten, denn 1 m ist kürzer als 2 m ist kürzer als 3 m. Die Relation *Größe der Verschiedenheit* ist erhalten, denn der Unterschied zwischen 1 m und 2 m ist genauso groß wie der Unterschied zwischen 2 m und 3 m. Die Relation *Verhältnis der Merkmalsausprägung* ist erhalten, 2 m sind doppelt so lang wie 1 m und 4 m sind doppelt so lang wie 2 m. Die Relation *absoluter Werte* ist nicht gegeben, denn die Länge eines Meters ist willkürlich gewählt, man hätte genauso gut eine kürzere oder längere Länge festlegen können. (Übrigens: Ein Meter entspricht genau der Strecke, die Licht in  $\frac{1}{299,792,458}$  s im Vakuum zurücklegt.) Da alle Relationen außer der Relation absoluter Werte gegeben sind, ist Verhältnisskalenniveau gegeben.


Die Nummern der Straßenbahnen der KVB weisen *bestenfalls* Nominalskalenniveau auf: Es ist vermutlich so gedacht, dass die Nummer die gefahrene Strecke anzeigen soll, das ist auch häufig der Fall. Unterschiedlich Nummern bezeichnen unterschiedliche Strecken, gleiche Nummern bezeichnen oft, aber nicht immer die gleiche Strecke: Gelegentlich fährt eine Linie 1 z.B. nicht zur Endhaltestelle Bensberg, sondern zur Endhaltestelle Zündorf. Man kann also nicht davon ausgehen, dass zwei Straßenbahnen mit der gleichen Nummer auch die gleiche Strecke fahren.

Über Schulnoten lässt sich immer wieder gut streiten. Ist die Benotung fair, ist die Relation von *Gleichheit/Verschiedenheit* erhalten, denn zwei unterschiedliche Schulleistungen sollten sich auch in unterschiedlichen Noten niederschlagen. Ungefähr gleiche Leistungen werden auch gleich benotet. Die Relation der *Ordnung* ist ebenfalls erhalten, denn eine 1 ist besser als eine 2 ist besser als eine 3. Die Relation der *Größe der Verschiedenheit* ist aber vermutlich meist selbst bei den besten und bemühtesten Lehrern nicht gegeben: Oft ist es der Leistungsunterschied zwischen einer 1 und einer 2 eben doch nicht genauso groß wie der Unterschied zwischen einer 2 und einer 3. Deshalb kann man sagen, dass Schulnoten *Ordinalskalenniveau* aufweisen. (Wir werden später sehen, warum es dann auch eigentlich nicht geschickt ist, eine “Durchschnittsnote” zu berechnen.)


Postleitzahlen weisen *Nominalskalenniveau* auf: Nur die Relation von *Gleichheit/Verschiedenheit* ist erhalten: Unterschiedliche Zahlen bedeuten unterschiedliche Postleitzahlenbereiche (z.B. Stadtteile), gleiche Postleitzahlen bedeuten, dass es auch der gleiche Postleitzahlenbereich ist. Die Relation der *Ordnung* ist schon nicht mehr wirklich gegeben: Zwar kann man eine grobe Ordnung nach Regionen feststellen, diese ist aber sehr unsystematisch.

## Kapitel 2: Beschreiben und Zusammenfassen

1. Zeichnet ein Histogramm der Variable *Alter* in der folgenden Tabelle.



2. Zeichnet ein Histogramm der Variable *Alter* aus der vorigen Aufgabe. Zeichnet dieses Mal jedoch eine sekundäre Häufigkeitsverteilung, beginnend mit der Kategorie “18-21 Jahre”.



3. Berechnet den Modus der Variable *Geschlecht* aus Aufgabe 1.

$M_o = \text{"weiblich"}$

4. Berechnet den Mittelwert der Variable *Alter* aus Aufgabe 1.

$M = 24.85$

5. Erläutert, warum es nicht sinnvoll ist, den Median der Variable *Geschlecht* zu berechnen.

Es ist nicht sinnvoll, den Median von Geschlecht zu berechnen, da sich die Merkmalsausprägungen (weiblich vs. männlich) in keine sinnvolle Ordnung bringen lassen. Entsprechend weist die Variable Geschlecht nur Nominalskalenniveau auf.